PAN 2014 Author Profiler - podręcznik użytkownika

Jacek Kowalski, Paweł Lipski

18 kwietnia 2016

1 Pobieranie kodu

`git clone https://github.com/tilius/author-profiler.git`

Kod był uruchamiany pod wersją 2.7.3 Pythona.

2 Instalacja bibliotek obliczeniowych

2.1 LIBLINEAR

Bibliotekę można pobrać z http://www.csie.ntu.edu.tw/ cjlin/liblinear/ (sekcja Download LIBLINEAR).

Po rozpakowaniu wystarczy wydać polecenie make. Powstały plik wykonywalne train oraz predict należy umieścić np. w /usr/local/bin (tak, aby były one dostępne przez PATH) pod następującym nazwami:

- train → linear-train
- predict → linear-predict

2.2 LIBSVM

Domyślnie aplikacja wykorzystuje LIBLINEAR. Użycie LIBSVM do obliczeń można wymusić poprzez przekazanie opcji `--libsvm` do polecenia train.py.

Bibliotekę można pobrać z http://www.csie.ntu.edu.tw/ cjlin/libsvm/ (sekcja Download LIBSVM).

Po rozpakowaniu wystarczy wydać polecenie make, a następnie umieścić trzy pliki wykonywalne (svm-train, svm-scale oraz svm-predict) np. w /usr/local/bin (tak, aby były one dostępne przez PATH).

3 Instalacja NTLK

Zgodnie z http://www.nltk.org/install.html, zakładając, że w systemie jest dostępny pip, należy uruchomić z shella:

```
sudo pip install -U numpy
sudo pip install -U pyyaml nltk
```

Na Ubuntu potrzebne pakiety można wcześniej ściągnąć poleceniem:

```
sudo apt-get install python-pip python-dev
```

Następnie należy ściągnąć dane NTLK (dokładniej Part Of Speech Tagger). Po wejściu w interaktywną powłokę Pythona należy wpisać:

```
import nltk
nltk.download("maxent_treebank_pos_tagger")
```

4 Uruchamianie

4.1 Domyślna struktura katalogów

Po wejściu w katalog repozytorium, należy utworzyć następujące 3 katalogi: `../corpora ../models ../classify-outputs`

W corpora należy umieścić korpus zgodny z formatem danych PAN 2014.

4.2 Trenowanie

```
train.py [-h] -i corpus_dir -o model_dir [--disjoint] [--libsvm]
```

Zakłada się, że `corpus_dir` jest katalogiem, w którym znajdują się pliki XML zgodne z formatem przewidzianym dla PAN 2014. Uprzednio utworzone przez train.py pliki w `model_dir` zostaną nadpisane.
Niestandardowa opcja `--disjoint` uruchamia trenowanie w trybie osobnego trenowania i klasyfikacji dla płci oraz wieku. Odpowiedni obiekt klasyfikatora wraz z wszystkimi niezbędnymi rezultatami zostanie w takim przypadku zapisany do folderu `model_dir`. Z tego względu nie przekazuje się tej opcji do `classify.py`.
Niestandardowa opcja `--libsvm` wykorzystuje bibliotekę LIBSVM (zamiast domyślnej LIBLINEAR). Również tutaj nie ma potrzeby przekazywania tej opcji do `classify.py` - informacja o bibliotece zostanie zaszyta w plikach modelu.

4.3 Klasyfikacja

`classify.py [-h] -i corpus_dir -m model_dir -o output_dir [--truth truth_file] [--accuracy accuracy_output_file]`

Zakłada się, że `corpus_dir` jest katalogiem, w którym znajdują się pliki XML zgodne z formatem przewidzianym dla PAN 2014. Uprzednio utworzone przez classify.py pliki w `output_dir` zostaną nadpisane.
Niestandardowa (i nieobowiązkowa) opcja `--truth truth_file` wskazuje plik zawierający faktyczne wyniki klasyfikacji - przyjmujemy format zgodny z tym używany w plikach PAN2013. Taki plik można też wygenerować za pomocą skryptu scripts/make-truth.sh, podając w parametrze katalog - wynik zostanie zapisany do pliku truth.dat w tym katalogu.
Niestandardowa (i nieobowiązkowa) opcja `--accuracy accuracy_output_file` wskazuje plik, do którego zostanie zapisana linia z informacją o trafności klasyfikacji (używane w skryptach).

5 Wyniki

5.1 Środowisko

Wszystkie testy były uruchamiane na Ubuntu 12.04 wirtualizowanym w VMware Player na Windows 7, na procesorze i7 przy włączonym VT-X.

We wszystkich testach użyto metryk CW, CNG, FW oraz POS.

5.2 Legenda

Styl rodzaj danych (fragment korpusu treningowego PAN14), na jakich uruchamiane były testy

N_{total} całkowity rozmiar danego fragmentu PAN14

N_{train}, N_{test} rozmiar korpusu treningowego i testowego, wydzielonych z wybranego fragmentu PAN14

N_{maj} rozmiar klasy większościowej w obrębie korpusu testowego

linear użyto biblioteki LIBLINEAR

svm użyto biblioteki LIBSVM

joint trenowanie i klasyfikacja były przeprowadzane dla klas będących kombinacją płci i wieku

disjoint trenowanie i klasyfikacja były przeprowadzane oddzielnie dla płci i wieku

5.3 Rezultaty dla poszczególnych konfiguracji

Styl	N_{total}	N_{train}, N_{test}	N_{maj}	**Konfiguracja**	**Dokładność**	**Czas**
Blog	147	75	17	linear, joint	28.00% (21/75)	1677 sec
				linear, disjoint	26.67% (20/75)	2833 sec
				svm, joint	16.00% (12/75)	1695 sec
				svm, disjoint	16.00% (12/75)	2711 sec
Reviews	4470	200	39	linear, joint	16.00% (32/200)	316 sec
				linear, disjoint	12.00% (24/200)	544 sec
				svm, joint	12.50% (25/200)	319 sec
				svm, disjoint	11.50% (23/200)	543 sec
		1000	133	linear, joint	28.30% (283/1000)	1590 sec
				linear, disjoint	28.90% (289/1000)	2895 sec
				svm, joint	13.30% (133/1000)	1683 sec
				svm, disjoint	13.30% (133/1000)	2912 sec
		2000	261	linear, joint	36.60% (732/2000)	3565 sec
				linear, disjoint	34.05% (681/2000)	6212 sec
				svm, joint	*(skipped)*	N/A
				svm, disjoint	*(skipped)*	N/A
Social media	7746	150	39	linear, joint	58.67% (88/150)	1536 sec
				linear, disjoint	56.00% (84/150)	2622 sec
				svm, joint	26.00% (39/150)	3257 sec
				svm, disjoint	25.33% (38/150)	5646 sec
		500	108	linear, joint	63.60% (318/500)	7489 sec
				linear, disjoint	*(skipped)*	N/A
				svm, joint	*(skipped)*	N/A
				svm, disjoint	*(skipped)*	N/A
		900	261	linear, joint	58.44% (526/900)	20321 sec
				linear, disjoint	*(skipped)*	N/A
				svm, joint	*(skipped)*	N/A
				svm, disjoint	*(skipped)*	N/A

6 Wnioski

Użycie LIBLINEAR przynosiło zdecydowanie lepsze rezulatata niż użycie LIBSVM. Ta druga w niektórych przypadkach zwracała dla wszystkich klasyfiko-

wanych obiektów klasę większościową, a w jeszcze innych jej dokładność była nawet mniejsza niż naiwnej klasyfikacji wg klasy większościowej.

Nie miało większego znaczenia dla dokładności, czy trenowanie i klasyfikacja były przeprowadzane dla klas będących kombinacją płci i wieku, czy oddzielnie dla płci i wieku. W tym drugim przypadku jednak znacznie więcej czasu pochłaniały obliczenia, które przeprowadzać trzeba było dla obu kategorii oddzielnie.

Zdecydowanie największą część czasu zajmowały obliczenia (tagowanie części mowy) wykonywane przez NTLK.

Najlepsze rezultaty udało się osiągnąć dla fragmentu socialmedia — nawet już na stosunkowo niewielkiej części tego fragmentu ($N_{train} = N_{test} = 150$ spośród 300 najmniejszych plików) wynosiła ona blisko 60%. Jednocześnie dalszy wzrost rozmiaru wydzielonych korpusów treningowych i testowych w ogóle nie przyniósł wzrostu dokładności, a nawet spowodował jej spadek — stąd też zaniechaliśmy prób na większej liczbie plików.

Jednocześnie, nawet na znacznie większych korpusach ($N_{train} = N_{test} = 2000$) wydzielonych z fragmentu reviews dokładność nie przekroczyła 40%.

We fragmencie blog dostarczone były pliki dla zaledwie 147 autorów, stąd też ciężko było sprawdzić dokładność dla większej liczby danych testowych i treningowych.

7 Wykresy

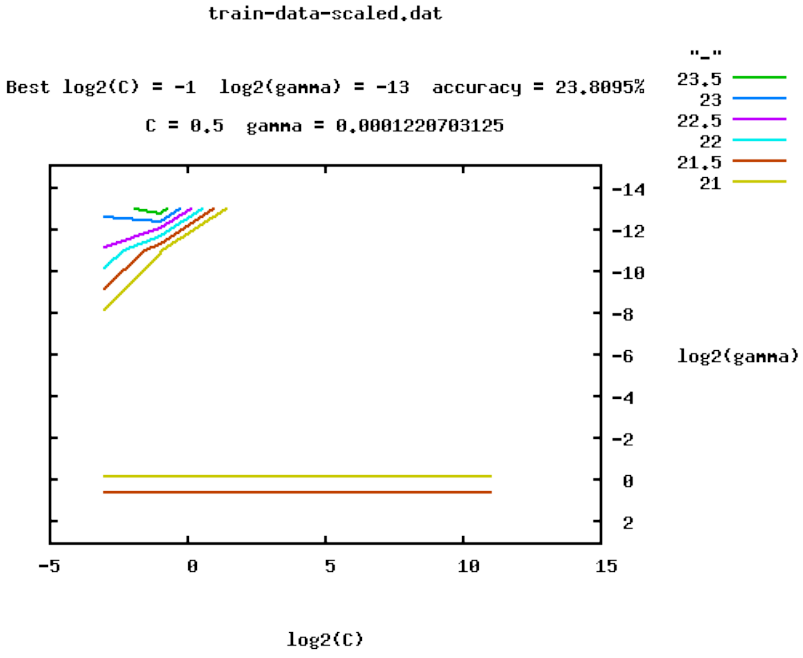

Rysunek 1: Wykres zależności dokładności od parametrów C oraz γ